Amostragem I

Aula 02 - Tipos de erro; Etapas operacionais; Tipos de pesquisas; Planos amostrais; Uso de questionários; O método probabilístico de amostragem.

Prof. Hemílio Fernandes Campos Coêlho
hemilio@de.ufpb.br
www.de.ufpb.br

Departamento de ESTATÍSTICA

Sumário

Tipos de erro em levantamentos amostrais

Etapas operacionais em um levantamento amostral

Principais tipos de pesquisas
- Exemplos de pesquisas censitárias

Esquemas e planos amostrais

Uso de questionários em pesquisas por amostragem
- Elaboração

O método probabilístico de amostragem

Tipos de erro em levantamentos amostrais

- **Erro amostral:** É o erro associado ao fato de que a variável de interesse é observada apenas na amostra.

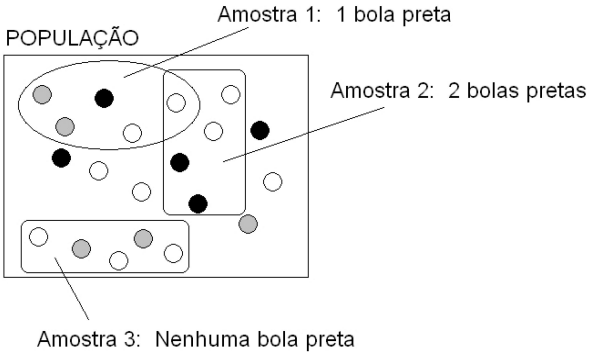

Tipos de erro em levantamentos amostrais

- **Erro não-amostral:** É o erro associado ao processo operacional envolvido em um levantamento amostral.

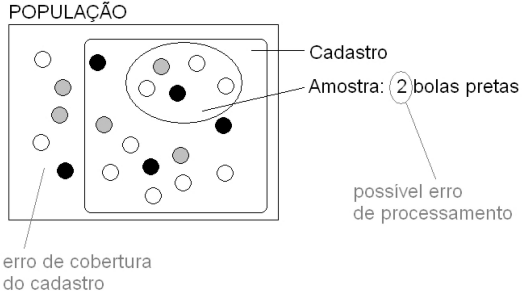

Tipos de erro em levantamentos amostrais

Biemer e Lyberg (2003) subdividem os erros não-amostrais nas seguintes categorias:

(a) Erros de especificação;

(b) Erros de cobertura do cadastro;

(c) Erros de processamento;

(d) Erros de mensuração;

(e) Erros de não-observação (não-resposta).

Etapas operacionais em um levantamento amostral

Do ponto de vista operacional, **Särndal, Swensson e Wretman (1992)** identificam as seguintes etapas de um levantamento amostral, e para cada uma, associam o respectivo erro de cada etapa:

ETAPA	DESCRIÇÃO	ERRO
1	Seleção da amostra	*Erro amostral e cobertura do cadastro*
2	Coleta de dados	*Erro de mensuração e de não-observação*
3	Processamento de dados	*Erro de processamento*
4	Estimação e análise	*Todos os erros das etapas 1, 2 e 3*
5	Disseminação dos resultados e avaliação pós-levantamento	-

Principais tipos de pesquisas

- **CENSOS:** Coletam informações sobre TODAS as unidades da população.
- **PESQUISAS POR AMOSTRAGEM:** Coletam informações sobre uma parte(amostra) da população.

Principais tipos de pesquisas

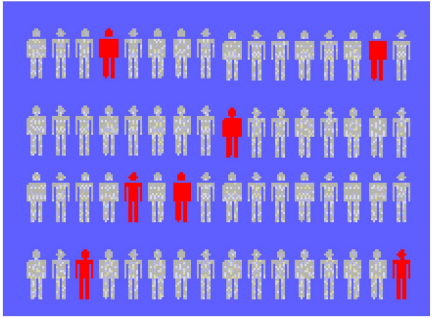

Buscam conhecer a população com base numa amostra.

Exemplos de pesquisas censitárias

- Censo Demográfico (2022). Para acessar publicações recentes dos dados do Censo 2022, clique **aqui** para maiores informações.
- Contagem populacional (1996)
- Censo Agropecuário (2017). Clique **aqui** para maiores informações.
- Primeiro censo brasileiro (1872). Clique **aqui** para maiores informações.

Sobre amostragem, outra frase

Definição

"Amostragem consiste em selecionar parte de uma população para observar, de modo que seja possível estimar alguma característica sobre toda a população".
(*Steven K. Thompson*)

comentários

O site **Khan Academy** fornece algumas perspectivas sobre quais preferências você teria para realizar uma pesquisa neste **link**. Seguem algumas:

- Contagem de quantos animais de estimação os seus colegas de sala possuem.
- Contagem de pessoas de sua cidade que pretendem participar de um bloco de carnaval de rua.
- Número de membros de sua família que gostam de chocolate.

A situação pode complicar um pouco

- Identificação de fatores relacionados à uma determinada doença.
- Estudo do número de pessoas que estão com malária no município do Conde - PB.
- Pesquisa de hábitos alimentares em alunos de um curso de graduação.
- Avaliação da qualidade de projetos em escolas da rede privada de uma cidade.
- Prioridades a serem elencadas na administração de um condomínio com 324 apartamentos.

Esquemas e planos amostrais

- **Plano amostral:** É a estratégia de associação de probabilidades às amostras possíveis de serem retiradas.

- **Esquema amostral:** É o conjunto de procedimentos físicos e computacionais realizados para compor a amostra de acordo com o plano amostral.

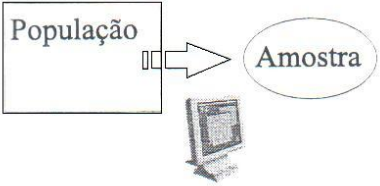

Esquema amostral:
Como retirar a amostra ?

Esquemas e planos amostrais

Os termos *amostra aleatória simples*, *amostra estratificada* e *amostra de conglomerados* são muito utilizados na discussão de pesquisas por amostragem, então estes serão brevemente definidos agora.

- **Amostra aleatória simples:** É a forma mais simples de amostra probabilística. Os elementos da população possuem mesma chance de serem sorteados.
- **Amostra aleatória estratificada:** A população é dividida em **grupos**, de acordo com as informações fornecidas por uma variável qualitativa. Esta variável qualitativa será chamada de **estrato**. Um plano amostral é aplicado dentro de cada grupo, o que garante um certo "equilíbrio" das informações coletadas graças ao estrato.

Esquemas e planos amostrais

- **Amostra de conglomerados:** Os elementos da população são agregados em grandes elementos amostrais, chamados **conglomerados**. Suponha que você queira fazer uma pesquisa com professores do ensino fundamental em João Pessoa, mas você não tem um cadastro de professores. Entretanto, você tem disponível um cadastro de escolas disponível. Dessa forma, sorteia-se primeiro as escolas, e dentro de cada uma, sorteia-se (ou não) amostras de professores. Veremos este procedimento com maior detalhamento no futuro.

Questionários - Elaboração

- Veremos nesta parte da disciplina uma breve introdução sobre como preparar algumas perguntas de questionários a serem utilizados numa pesquisa por amostragem.
- O passo mais importante em elaborar um questionário é ter uma **ideia precisa do objetivo principal da pesquisa**.
- Com esta ideia, elabore um roteiro de perguntas que podem ser úteis para se chegar ao objetivo que foi estabelecido.

Questionários - Elaboração

- Veremos nesta parte da disciplina uma breve introdução sobre como preparar algumas perguntas de questionários a serem utilizados numa pesquisa por amostragem.
- O passo mais importante em elaborar um questionário é ter uma **ideia precisa do objetivo principal da pesquisa**.
- Com esta ideia, elabore um roteiro de perguntas que podem ser úteis para se chegar ao objetivo que foi estabelecido.

Dicas importantes

- Sempre teste suas questões antes de iniciar a pesquisa (fase de pré-teste);
- Construa perguntas simples e extremamente compreensíveis;
- Use questões específicas ao invés de perguntas que podem levar à fuga dos objetivos principais da pesquisa;
- Relacione sempre suas questões aos conceitos relacionados aos propósitos da pesquisa para que não haja confundimento de análise;
- Decida se vão ser utilizadas questões abertas ou fechadas;
- Registre adequadamente sempre os resultados de sua pesquisa com base no perfil do público pesquisado;

Dicas importantes

- Evite questões que de algum modo induzam o entrevistado a responder;
- Considere a importância social da pesquisa que você está conduzindo e seja capaz de produzir perguntas que gerem respostas honestas;
- Evite duplas negativas em uma pergunta, para não confundir o entrevistado;
- Utilize perguntas com itens a serem respondidos (pergunta forçada) ao invés de perguntas do tipo “concordo” ou “discordo” em que há abertura para respostas longas;
- Formule perguntas que não induzam mais de uma opinião ao respondente;
- Tenha atenção ao efeito de ordem das perguntas.

O método probabilístico de amostragem

Um método de amostragem é considerado probabilístico se:

1. É possível definir o conjunto de todas as amostras possíveis de serem retiradas ($\mathcal{S}$) de acordo com o procedimento de seleção da amostra empregado:

$$\mathcal{S} = \{S_1, S_2, \ldots, S_M\}$$

2. A amostra é selecionada por um **processo físico de aleatorização** que associa a cada amostra possível S_i uma **probabilidade de seleção**, denotada por $P(S_i)$.
3. O procedimento de seleção da amostra dá uma probabilidade de seleção positiva para <u>cada elemento</u> da população. Esta probabilidade será chamada de **probabilidade de inclusão**, que será denotada por π_k. Tem-se que

$$\pi_k = P(\text{elemento } k \text{ pertencer à amostra}) = P(k \in S)$$

continuação

- As amostras são extraídas de uma **população finita** (ou universo), denotada por $\mathcal{U}$. Em outras palavras, $\mathcal{U}$ representa o conjunto dos índices que identificam os elementos que compõem a população finita, de tamanho N, sob estudo:

$$\mathcal{U} = \{1, 2, 3, \ldots, N\}$$

- Note que dessa população podemos escolher várias amostras possíveis, as quais são subconjuntos de $\mathcal{U}$. Um amostra em particular é denotada por S, ou seja, é um subconjunto de $\mathcal{U}$, e contém n elementos.

- As amostras sempre serão coletadas com o objetivo de medir/avaliar/estudar uma **variável de interesse**. Denote por Y uma variável de interesse e, por y_k, o valor dessa variável associado ao k-ésimo elemento da população.

continuação

- Ou seja, note que temos um bijeção na relação entre $\mathcal{U}$ e Y. Ou seja,

$$\mathcal{U} = \{1, 2, 3, \ldots, N\} \Longrightarrow Y = \{y_1, y_2, y_3, \ldots, y_N\}$$

- Nessa estrutura populacional, Y recebe o nome de **população conceitual de respostas**. Isto porque sabemos que os valores da variável de interesse existem na população, porém, nas situações em que é inviável a realização de um censo, só conheceremos alguns destes valores através da amostra.

continuação

- Suponha que temos uma população constituída por 4 elementos: $\mathcal{U} = \{1, 2, 3, 4\}$.

- Se temos por exemplo o interesse em obter uma amostra de tamanho $n = 2$, note que podemos selecionar seis amostras possíveis de $\mathcal{U}$:

$$S_1 = \{1, 2\} \qquad S_2 = \{2, 3\} \qquad S_3 = \{1, 3\}$$

$$S_4 = \{2, 4\} \qquad S_5 = \{1, 4\} \qquad S_6 = \{3, 4\}$$

- Lembre que cada possível amostra S da população possuirá uma **probabilidade de seleção conhecida**, e que a soma das probabilidades de seleção é igual a 1.

continuação

- Um possível plano amostral para uma amostra de tamanho 2 poderia ser:

$$P(S_1) = 1/3 \qquad P(S_2) = 1/6 \qquad P(S_3) = 0$$

$$P(S_4) = 0 \qquad P(S_5) = 0 \qquad P(S_6) = 1/2$$

- Note que

$$\sum_i P(S_i) = P(S_1) + P(S_2) + P(S_3) + P(S_4) + P(S_5) + P(S_6) = 1$$

continuação

- Em amostragem, desde que cada amostra possível de ser selecionada tem uma probabilidade conhecida de ser selecionada, teremos então agora como determinar a probabilidade de que *cada elemento* da população seja incluído na amostra.

- Ou seja, a **probabilidade de inclusão** na amostra do k-ésimo elemento da população é dada por

$$P\left(\text{elemento } k \text{ ser incluído na amostra}\right) = P\left(k \in S\right) = \pi_k$$

- A obtenção de π_k é feita somando-se todas as probabilidades de seleção das amostras que contêm o elemento.

continuação

- Para a amostra descrita anteriormente, denote novamente por π_k a probabilidade do elemento k pertencer a amostra, ou seja:

$$P(k \in S) = \pi_k$$

- Então, tem-se que

$$\begin{aligned}
\pi_1 &= P(S_1) + P(S_3) + P(S_5) = 1/3 + 0 + 0 = 1/3 \\
\pi_2 &= P(S_1) + P(S_2) + P(S_4) = 1/3 + 1/6 + 0 = 1/2 \\
\pi_3 &= P(S_2) + P(S_3) + P(S_6) = 1/6 + 0 + 1/2 = 2/3 \\
\pi_4 &= P(S_4) + P(S_5) + P(S_6) = 0 + 0 + 1/2 = 1/2
\end{aligned}$$

- Note que todos os π_k's são positivos.

Alguns comentários

- É óbvio que na prática nunca escreveremos todas as possíveis amostras ou calcular suas respectivas probabilidades. Teríamos um procedimento sempre exaustivo se isto fosse necessário.
- Porém, sempre é importante esclarecer que essa fundamentação é que torna possível toda a inferência por trás do método de amostragem.
- O uso de amostras probabilísticas garante que erros amostrais apresentados anteriormente sejam evitados.
- O uso de uma amostra probabilística evita que o entrevistador escolha quem vai fazer parte da pesquisa, graças ao método de seleção aleatória.

Alguns comentários

- No âmbito da amostragem probabilística, poderemos determinar o quão provável é nossa amostra de ser uma boa amostra.
- Uma amostra probabilística não é a única garantia representatividade em relação à característica de interesse, mas poderemos quantificar de modo geral que esta amostra é capaz de explicar a população de interesse através de alguns critérios.
- A noção é a mesma de um intervalo de confiança: Não sabemos se um intervalo com 95% de confiança que construímos pra média contém o verdadeiro valor da média populacional. Porém, sabemos que se as suposições necessárias para a construção do intervalo são válidas, e possamos construir este intervalo para várias e várias amostras que podemos coletar, em 95% destes intervalos teremos a cobertura do verdadeiro valor da média populacional.

Exercício extra classe

- Considere uma população artificial que contém $N = 8$ elementos. Ou seja:

$$\mathcal{U} = \{1, 2, 3, 4, 5, 6, 7, 8\}$$

- Considerando uma variável de interesse Y conceitualmente conhecida na população, temos que $Y = \{y_1, y_2, y_3, y_4, y_5, y_6, y_7, y_8\} = \{1, 2, 4, 4, 7, 7, 7, 8\}$.
- Suponha que exista o interesse em obter uma amostra de tamanho $n = 4$.
- **Exercício:** Apresente:
  - **(a)** Um script em **R** que apresente **todas as amostras possíveis** de tamanho $n = 4$.
  - **(b)** Um banco de dados com as seguintes estatísticas de cada amostra: Média; Proporção de valores maiores que 4.
  - **(c)** Você percebe alguma relação entre os procedimentos utilizados e algum conceito de inferência estatística?