Amostragem I

Aula 09 - Análise da eficiência de um plano de amostragem sistemática; Amostragem de Bernoulli; Amostragem de Poisson

Prof. Hemílio Fernandes Campos Coêlho
hemilio@de.ufpb.br
www.de.ufpb.br

Departamento de ESTATÍSTICA

Sumário

Análise da Eficiência de um plano AS

Amostragem de Bernoulli - BE

Amostragem de Poisson - POI

Análise da Eficiência de um plano AS

- Por simplicidade, considere o caso em que $c = 0$. Nessa situação, $a = N/n$. Logo,

$$\hat{t}_{y\pi} = at_s = N\overline{y}_{S_r}$$

Análise da Eficiência de um plano AS

- Por simplicidade, considere o caso em que $c = 0$. Nessa situação, $a = N/n$. Logo,

$$\hat{t}_{y\pi} = at_s = N\overline{y}_{S_r}$$

$$Var_{AS}\left(\hat{t}_{y\pi}\right) = Nn\sum_{r=1}^{a}\left(\overline{y}_{S_r} - \overline{y}_U\right)^2$$

- Por outro lado, note que

Análise da Eficiência de um plano AS

- Por simplicidade, considere o caso em que $c = 0$. Nessa situação, $a = N/n$. Logo,

$$\hat{t}_{y\pi} = at_s = N\overline{y}_{S_r}$$

$$Var_{AS}\left(\hat{t}_{y\pi}\right) = Nn\sum_{r=1}^{a}\left(\overline{y}_{S_r} - \overline{y}_U\right)^2$$

- Por outro lado, note que

$$\begin{aligned}\sum_{k\in U}\left(y_k - \overline{y}_U\right)^2 &= \sum_{r=1}^{a}\sum_{k\in S_r}\left(y_k - \overline{y}_{S_r}\right)^2 + n\sum_{r=1}^{a}\left(\overline{y}_{S_r} - \overline{y}_U\right)^2 \\ SQT &= SQD + SQE\end{aligned}$$

Análise da Eficiência de um plano AS

- Dessa forma, fica claro então que

$$Var_{AS}\left(\hat{t}_{y\pi}\right) = N \times SQE$$

- Defina agora a seguinte medida de homogeneidade:

$$\delta = 1 - \frac{(N-1)SQD}{(N-a)SQT}$$

- Temos que $$-\left(\frac{a-1}{N-a}\right) \leq \delta \leq 1$$

Análise da Eficiência de um plano AS

- É possível mostrar ainda que, quando $c = 0$ (e a é um inteiro),

$$
\begin{aligned}
Var_{AS}\left(\hat{t}_{y\pi}\right) &= \frac{N^2 S_{yU}^2}{n}\left[(1-f)+(n-1)\delta\right] \\
&= Var_{AAS}\left(\hat{t}_{y\pi}\right)\left[1+\frac{(n-1)}{(1-f)}\delta\right]
\end{aligned}
$$

continuação

Um resultado interessante é o seguinte:

$$
\begin{aligned}
Var_{AS}\left(\hat{t}_{y\pi}\right) &= \frac{N^2 S_{yU}^2}{n}\left[(1-f)+(n-1)\delta\right] \\
&= Var_{AAS}\left(\hat{t}_{y\pi}\right)\left[1+\frac{(n-1)}{1-f}\delta\right]
\end{aligned}
$$

Portanto, $EPA_{AS} = \dfrac{Var_{AS}\left(\hat{t}_{y\pi}\right)}{Var_{AAS}\left(\hat{t}_{y\pi}\right)} = 1 + \dfrac{(n-1)}{1-f}\delta.$

Logo, AS será mais eficiente que AAS, apenas quando $\delta < 0$.

Essa situação ocorrerá dependendo da **ordenação** dos elementos na população.

Exemplo

Considere o caso em que $N = 20$ e $n = 4$. Tem-se que $a = 5$. Suponha ainda que $y_k = k$. Nesse caso,

$$Var_{AAS}\left(\hat{t}_{y\pi}\right) = 20^2\left(1 - \frac{4}{20}\right)\frac{35}{4} = 2800,$$

independentemente da ordenação. Os quadros (a), (b) e (c) a seguir ilustram o efeito da ordenação da população na eficiência de um plano AS:

Exemplo

Quadro (a)

s_1	s_2	s_3	s_4	s_5
1	2	3	4	5
10	9	8	7	6
11	12	13	14	15
20	19	18	17	16
42	**42**	**42**	**42**	**42**

Com $N = 20$ e $a = 5$, tem-se que $SQT = 665$, $SQD = 665$ e $SQE = 0$. Logo:

$$
\begin{aligned}
Var_{AS}\left(\hat{t}_{y\pi}\right) &= N \times SQE = 20 \times 0 = 0 \\
Var_{AAS}\left(\hat{t}_{y\pi}\right) &= 2800 \\
\delta &= 1 - \frac{(20-1) \times 665}{(20-5) \times 665} = -\frac{4}{15} = -0,26667
\end{aligned}
$$

Exemplo

Quadro (b)

s_1	s_2	s_3	s_4	s_5
1	5	9	13	17
2	6	10	14	18
3	7	11	15	19
4	8	12	16	20
10	**26**	**42**	**58**	**74**

Com $N = 20$ e $a = 5$, tem-se que $SQT = 665$, $SQD = 25$ e $SQE = 640$. Logo:

$$
\begin{aligned}
Var_{AS}\left(\hat{t}_{y\pi}\right) &= N \times SQE = 20 \times 640 = 12800 \\
Var_{AAS}\left(\hat{t}_{y\pi}\right) &= 2800 \\
\delta &= 1 - \frac{(20-1) \times 25}{(20-5) \times 665} = \frac{380}{399} = 0,95238
\end{aligned}
$$

Exemplo

Quadro (c)

s_1	s_2	s_3	s_4	s_5
13	19	2	14	11
6	1	17	3	5
12	20	15	4	16
9	18	8	7	10
40	**58**	**42**	**28**	**42**

Com $N = 20$ e $a = 5$, tem-se que $SQT = 665$, $SQD = 551$ e $SQE = 114$. Logo:

$$
\begin{aligned}
Var_{AS}\left(\hat{t}_{y\pi}\right) &= N \times SQE = 20 \times 114 = 12800 \\
Var_{AAS}\left(\hat{t}_{y\pi}\right) &= 2800 \\
\delta &= 1 - \frac{(20-1) \times 551}{(20-5) \times 665} = -\frac{26}{525} = -0,04952
\end{aligned}
$$

Comentários

- Os exemplos apresentados mostram o cuidado que se deve ter com a simplicidade de implementação do plano, pois esta simplicidade pode gerar uma perda grande de eficiência. Porém, se a população estiver arranjada de uma forma igual à apresentada no quadro (a), muitos ganhos em eficiência poderão ser obtidos.
- Sob o esquema amostral apresentado, não há estimador centrado para a variância do estimador do total.
- Uma situação por várias vezes empregada é a utilização de $Var_{AAS}\left(\hat{t}_{y\pi}\right)$ para estimar a variância do estimador sob um plano AS.
- Porém, a menos que $\delta = 0$, este estimador pode ser bastante tendencioso. Existem soluções para corrigir o problema de estimação da variância sob um plano de amostragem sistemática.

Solução 1

- No caso de estimação de uma média populacional, quando se supõe que não houve algum esquema de ordenação prévia das informações ou que a população esteja distribuída aleatoriamente no cadastro de seleção das variáveis, é utilizar um estimador similar ao do estimador de variância utilizado para amostragem aleatória simples, com uma sucinta modificação, dada por:

$$\hat{\mathrm{Var}}_1(\overline{y}_{AS}) = \left(\frac{1}{n} - \frac{1}{N}\right) \frac{1}{n-1} \sum_{k=1}^{n} (y_k - \overline{y}_{AS})^2$$

- Ao se considerar a estimação de um total, basta notar que

$$\hat{\mathrm{Var}}_1(\hat{t}_y) = N^2 \hat{\mathrm{Var}}_1(\overline{y}_{AS})$$

Solução 2

- No caso em que haja evidência de que a população está ordenada segundo uma "estratificação" de modo que as médias em cada intervalo variam (exemplo: Um ordenamento dos valores da variável de interesse na amostra em ordem crescente), Cochran(1977) sugere que a estimativa da variância do estimador da média seja dada pela seguinte expressão:

$$\hat{\mathrm{Var}}_2(\overline{y}_{AS}) = \left(\frac{1}{n} - \frac{1}{N}\right) \frac{1}{2(n-1)} \sum_{k=1}^{n-1} \left(y_k - y_{(k+a)}\right)^2$$

- Ao se considerar a estimação de um total, basta notar que

$$\hat{\mathrm{Var}}_2(\hat{t}_y) = N^2 \hat{\mathrm{Var}}_2(\overline{y}_{AS})$$

A forma da expressão algébrica $SQT = SQD + SQE$ pode ser demonstrada a partir da estrutura do plano amostral, conforme apresentado a seguir: Basta considerar um "zero interessante", denotado por $\overline{y}_{S_r} - \overline{y}_{S_r}$. Note que:

$$\begin{aligned}
\sum_{k\in U}(y_k-\bar{y}_U)^2 &= \sum_{r=1}^{a}\sum_{k\in S_r}[y_k-\bar{y}_{S_r}+y_{S_r}-\bar{y}_U]^2 = \sum_{r=1}^{a}\sum_{k\in S_r}[(y_k-\bar{y}_{S_r})+(\bar{y}_{S_r}-\bar{y}_U)]^2 && (1)\\
&= \sum_{r=1}^{a}\sum_{k\in S_r}\left\{(y_k-\bar{y}_{S_r})^2+2\,(y_k-\bar{y}_{S_r})\,(\bar{y}_{S_r}-\bar{y}_U)+(\bar{y}_{S_r}-\bar{y}_U)^2\right\} && (2)\\
&= \sum_{r=1}^{a}\sum_{k\in S_r}(y_k-\bar{y}_{S_r})^2 + 2\sum_{r=1}^{a}(\bar{y}_{S_r}-\bar{y}_U)\underbrace{\sum_{k\in S_r}(y_k-\bar{y}_{S_r})}_{=0} + \sum_{r=1}^{a}\sum_{k\in S_r}(\bar{y}_{S_r}-\bar{y}_U)^2 && (3)\\
&= \sum_{r=1}^{a}\sum_{k\in S_r}(y_k-\bar{y}_{S_r})^2 + \sum_{r=1}^{a}\sum_{k\in S_r}(\bar{y}_{S_r}-\bar{y}_U)^2 && (4)\\
&= \sum_{r=1}^{a}\sum_{k\in S_r}(y_k-\bar{y}_{S_r})^2 + \sum_{r=1}^{a}\left[\sum_{k\in S_r}1\right](\bar{y}_{S_r}-\bar{y}_U)^2 && (5)\\
&= \sum_{r=1}^{a}\sum_{k\in S_r}(y_k-\bar{y}_{S_r})^2 + n\sum_{r=1}^{a}(\bar{y}_{S_r}-\bar{y}_U)^2 \quad \blacksquare && (6)
\end{aligned}$$

Amostragem de Bernoulli - BE

- Um plano amostral BE consiste em uma série de experimentos independentes, um para cada elemento da população.
- O plano atribui probabilidade igual de seleção π, e de não seleção, $1 - \pi$, a cada elemento listado no cadastro.
- Consequentemente, o tamanho da amostra, denotado por n_S é uma variável aleatória, onde $n_S \sim Bin(N, \pi)$.
- Sob um plano BE, tem-se que:

$$p(s) = \pi^{n_S} (1 - \pi)^{N - n_S}, \quad \pi_k = \pi \quad \pi_{kl} = \pi^2$$

Esquema Amostral

- Considere um valor para π ($0 < \pi < 1$);
- Denote por $\varepsilon_1, \varepsilon_2, \ldots, \varepsilon_N$, uma série de N realizações de uma Uniforme (0,1);
- Se $\varepsilon_k < \pi$, então, o elemento k é selecionado para compor s. Do contrário, $k \notin S$.

Estimação

- Considere a estimação do total populacional de uma população finita sobre um plano BE.

Resultado: Sob um plano BE, o estimador de HT assume a seguinte forma

$$\hat{t}_{y\pi} = \pi^{-1} \sum_{k \in S} y_k$$

e tem como variância

$$Var_{BE}\left(\hat{t}_{y\pi}\right) = \left(\frac{1}{\pi} - 1\right) \pi^{-1} \sum_{k \in U} y_k^2$$

Estimação

Um estimador centrado para a variância do plano Bernoulli é dado por

$$\hat{Var}_{BE}\left(\hat{t}_{y\pi}\right) = \frac{1}{\pi}\left(\frac{1}{\pi} - 1\right)\pi^{-1}\sum_{k\in S} y_k^2$$

Prova: Exercício.

Comentários

- Os planos AAS, AS e BE, vistos até o momento, possuem a característica comum de atribuir probabilidade igual de seleção para as amostras.
- Em alguns livros, os planos que compartilham essa característica são chamados de “EPSEM”, abreviação de *Equal Probability Selection Methods*
- Na prática, porém, planos que permitem probabilidades desiguais de seleção são frequentes. A seguir, serão vistos alguns desses planos.

Amostragem de Poisson - POI

- O plano amostral POI é uma generalização do plano BE, uma vez que permite a utilização de robabilidades de inclusão diferentes no cadastro.
- Denotando por π_k a probabilidade de inclusão do elemento k, tem-se que $p(S)$ é dada or

$$p(S) = \prod_{k \in S} \pi_k \prod_{k \in (U-S)} (1 - \pi_k)$$

- Sob um plano POI, $\pi_{kl} = \pi_k \pi_l$.

Esquema Amostral

- Considere dados os valores π_k para $k = 1, 2, \ldots, N$.
- Denote por $\varepsilon_1, \varepsilon_2, \ldots, \varepsilon_N$ uma série de N realizações de uma Uniforme (0,1).
- Se $\varepsilon_k < \pi_k$, então, o elemento k é selecionado para compor s. Do contrário, $k \notin S$.
- Da mesma forma que no plano BE, sob um plano POI, o tamanho da amostra, denotado por n_S é uma variável aleatória, com

$$E_{POI}(n_S) = \sum_{k \in U} \pi_k \qquad \text{e} \qquad Var_{POI}(n_S) = \sum_{k \in S} \pi_k (1 - \pi_k)$$

Estimação

- Considere a estimação do total populacional de uma população finita, sob um plano POI.
- **Resultado:** Sob um plano POI, o estimador de HT assume a forma geral

$$\hat{t}_{y\pi} = \sum_{k \in S} \frac{y_k}{\pi_k}$$

- e tem como variância

$$Var_{POI}\left(\hat{t}_{y\pi}\right) = \sum_{k \in U} \frac{1}{\pi_k}\left(\frac{1}{\pi_k} - 1\right) y_k^2$$

Estimação

Um estimador centrado para a variância do plano POI é dado por

$$\hat{Var}_{POI}\left(\hat{t}_{y\pi}\right) = \sum_{k \in S} \left(\frac{1}{\pi_k} - 1\right) \left(\frac{y_k}{\pi_k}\right)^2$$

Prova: Exercício.